Examen domiciliario de R

Laboratorio para el Análisis de Datos – Universidad Torcuato Di Tella

Máxima Bernhardt Larraignet Pedro Somoza Santiago Parodi
Agustín Nicolás Rossi

Octubre de 2026

Profesores: Ian Evangelos Bounos y Pedro Dolanyi Plaza

1. Análisis de datos: Encuesta Permanente de Hogares

Dataset y preguntas

Trabajamos con la base usuaria individual de la Encuesta Permanente de Hogares (EPH) del INDEC, primer trimestre de 2026, el último trimestre publicado al momento de hacer el trabajo. La base tiene 43,739 personas de los 31 aglomerados urbanos relevados y 234 variables. Se descargó de la página de bases de datos del INDEC (archivo `EPH_usu_1_Trim_2026_txt.zip`) y se guardó en `analisis_datos/data/`. Las variables y sus códigos son los mismos que usa el paquete `eph` del ejercicio de clase. Nos hacemos tres preguntas sobre el mercado de trabajo y la distribución del ingreso:

P1. ¿Existe una brecha de género en el ingreso laboral? ¿Cuánto se explica por diferencias en las horas trabajadas y cómo varía según el nivel educativo?

P2. ¿Qué proporción de los asalariados es informal (sin descuento jubilatorio)? ¿Cómo varía por edad y región, y qué penalidad salarial implica?

P3. ¿Cómo difiere la desigualdad del ingreso per cápita familiar entre las regiones del país?

Código: `analisis_datos/funciones.R: preparar_eph(), cuantil_ponderado(), gini_ponderado(), curva_lorenz(); script_principal.R`

Ponderadores. La EPH es una muestra: cada persona encuestada representa a muchas personas de la población, según su *factor de expansión*. Para que las medias, medianas y tasas describan a la población (y no a la muestra) usamos promedios y cuantiles ponderados, con el ponderador que el INDEC indica para cada caso: `PONDERA` para tasas generales, `PONDIIO` para el ingreso de la ocupación principal y `PONDIH` para el ingreso per cápita familiar. Estos dos últimos valen 0 para quienes no declararon su ingreso, y su peso se redistribuye entre quienes sí lo hicieron (lo verificamos con `stopifnot()`). Implementamos el cuantil y el Gini ponderados en `funciones.R`.

1.1. Exploración y limpieza previa

Código: `script_principal.R: secciones 0 y 1`

Antes de responder las preguntas revisamos los valores de cada variable. Los ocupados con ingreso cero son, sobre todo, asalariados (218 casos) que no cobraron en el mes y trabajadores familiares sin remuneración (67). Los excluimos de las preguntas sobre ingresos, porque lo que nos interesa es el nivel del ingreso de quienes sí cobran. El ingreso por hora se calcula como

ingreso mensual / (horas semanales × 30/7), sólo para quienes trabajaron una cantidad positiva de horas.

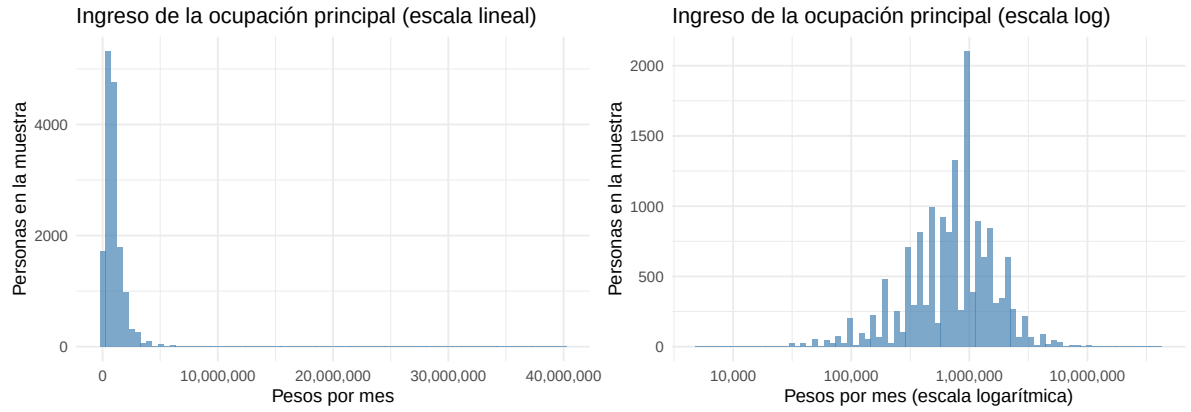


Figura 1: Ingreso mensual de la ocupación principal de los ocupados, en escala lineal y logarítmica.

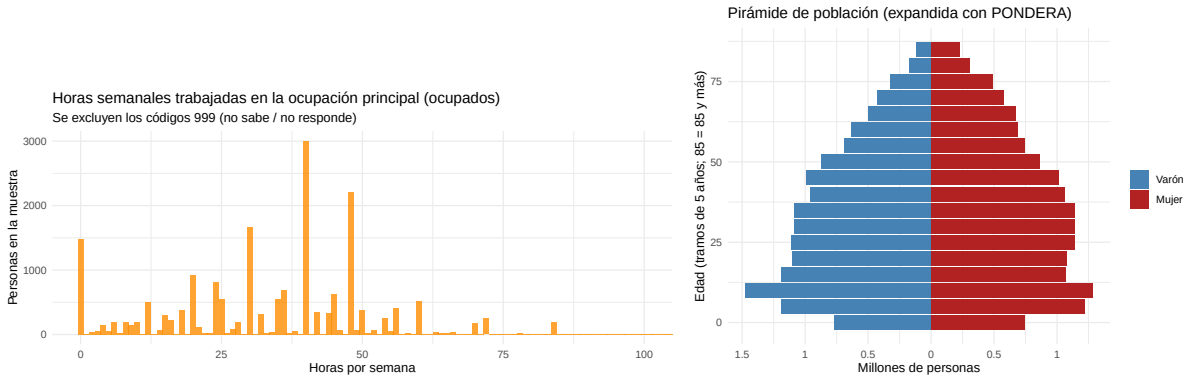


Figura 2: Horas semanales trabajadas (izquierda) y pirámide de población expandida (derecha).

- El ingreso es muy asimétrico: en escala lineal casi toda la masa se concentra a la izquierda, con una cola que llega a 40 millones de pesos mensuales. En escala log la distribución es aproximadamente simétrica. Por eso preferimos medianas (robustas a valores extremos) y gráficos en escala logarítmica.
- Los ingresos y las horas se declaran redondeados (picos en 500,000, 1,000,000… y en 40, 45 y 48 horas). Esto hace que las medianas sean valores "redondos" y conviene leerlas como aproximaciones.
- La pirámide de población expandida tiene la forma esperada para la Argentina urbana (más mujeres en las edades avanzadas), lo que sugiere que los ponderadores funcionan bien.

1.2. P1: Brecha de género en el ingreso laboral

Código: `script_principal.R: Pregunta 1`

Universo: ocupados con ingreso positivo en la ocupación principal (15,448 casos, que representan 13.1 millones de personas). Ponderador: `PONDIIO`.

	Varones	Mujeres	Brecha (%)
Ingreso mensual medio	$1,270,381	$898,054	29.3
Ingreso mensual mediano	$1,000,000	$700,000	30.0
Horas semanales medias	37.4	28.3	24.3
Ingreso por hora medio	$8,034	$7,380	8.1
Ingreso por hora mediano	$5,833	$5,444	6.7
% con superior completo	19.2 %	31.3 %	

Brecha = (varón − mujer)/varón. Positiva: las mujeres ganan menos.

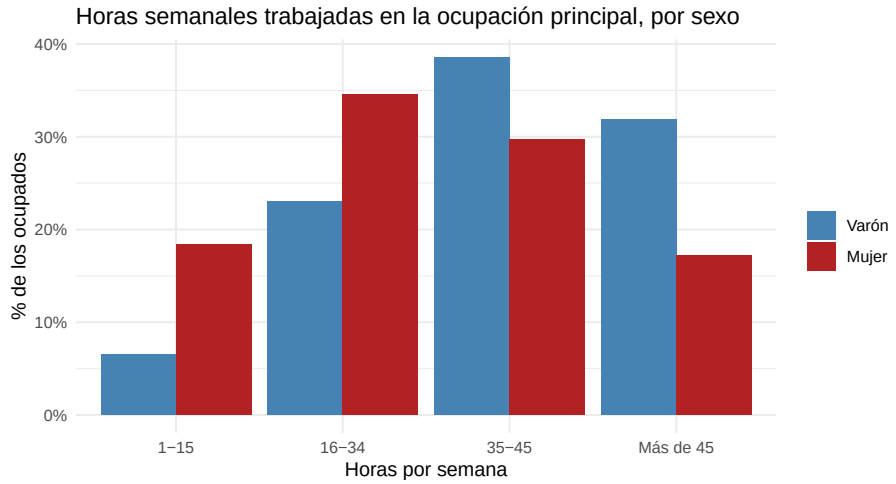


Figura 3: Distribución de las horas semanales trabajadas, por sexo.

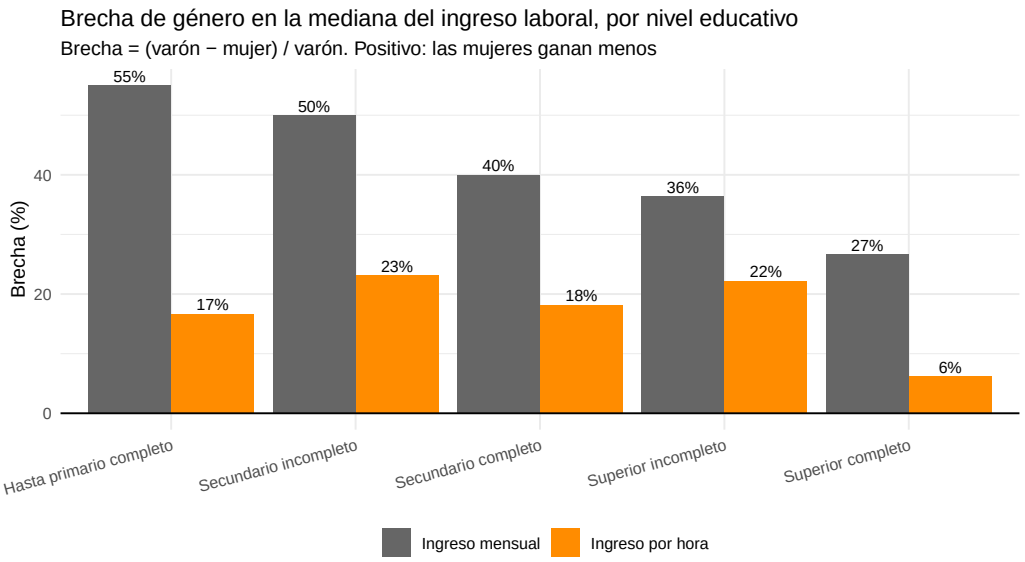


Figura 4: Brecha de género en la mediana del ingreso mensual y por hora, por nivel educativo.

	Mediana mensual		Horas medias		Brecha (%)	
Nivel educativo	Varón	Mujer	Varón	Mujer	Mensual	Por hora
Hasta primario completo	800,000	360,000	40.2	27.3	55.0	16.7
Secundario incompleto	800,000	400,000	38.8	29.7	50.0	23.2
Secundario completo	1,000,000	600,000	41.9	32.8	40.0	18.2
Superior incompleto	1,100,000	700,000	36.8	31.7	36.4	22.2
Superior completo	1,500,000	1,100,000	39.2	33.0	26.7	6.3

Sí, hay una brecha de género importante en el ingreso mensual: las mujeres ocupadas ganan alrededor de un 30 % menos que los varones, tanto en la media como en la mediana.

La mayor parte se explica por las horas trabajadas. Las mujeres trabajan, en promedio, 9 horas semanales menos en el mercado (28.3 vs. 37.4): más de la mitad de ellas (53 %) trabaja menos de 35 horas, contra el 30 % de los varones, y sólo el 17 % trabaja más de 45 horas (32 % de los varones). Medida *por hora*, la brecha cae a 8 % en la media y 7 % en la mediana. Esto no implica que la brecha mensual "no exista": refleja que las mujeres dedican menos horas al trabajo remunerado (en buena medida por la carga de trabajo doméstico y de cuidado no remunerado), algo que la EPH no permite medir directamente.

Pero la brecha por hora agregada esconde un efecto composición. Dentro de los niveles educativos que no llegan a superior completo, la brecha por hora es bastante mayor que la agregada: entre 17 % y 23 %. La explicación es que las mujeres ocupadas están más educadas que los varones ocupados (31 % vs. 19 % con superior completo), y la educación paga más. Al comparar todo junto, la mayor educación de las mujeres compensa en parte su menor ingreso por hora a igual nivel educativo. Es la misma lógica de la paradoja de Simpson y del sesgo por variable omitida vista en clase: la comparación agregada mezcla dos efectos.

Por nivel educativo, la brecha mensual es mucho mayor entre las personas menos educadas (55 % hasta primario completo) que entre las universitarias (27 %), porque en los niveles bajos la diferencia de horas es más grande (40 vs. 27 horas). Entre las personas con título universitario la brecha por hora es la más baja (6 %).

Limitación: son diferencias descriptivas. No controlan por ocupación, sector, experiencia ni formalidad, así que no miden discriminación salarial.

1.3. P2: Informalidad de los asalariados

Código: `script_principal.R: Pregunta 2`

Universo: asalariados ocupados que respondieron si les hacen descuento jubilatorio (13,938 casos). Consideramos informal a quien no tiene descuento jubilatorio (`PP07H` = 2), la definición estándar de la EPH. Tasas ponderadas con `PONDERA`; salarios con `PONDIIO`.

Tasa de informalidad de los asalariados: 37.9 %.

Edad	Tasa	Región	Tasa	Nivel educativo	Varones	Mujeres
18 a 25	62.3 %	Cuyo	48.4 %	Hasta primario compl.	50.9 %	64.6 %
26 a 40	38.6 %	NOA	42.4 %	Secundario incompl.	57.9 %	70.1 %
41 a 60	27.6 %	NEA	41.4 %	Secundario compl.	34.5 %	47.9 %
Más de 60	42.3 %	Pampeana	37.5 %	Superior incompl.	27.7 %	40.9 %
		GBA	37.1 %	Superior compl.	15.4 %	17.0 %
		Patagonia	19.7 %			

Menores de 18: 93.5 %, pero con sólo 45 casos en la muestra.

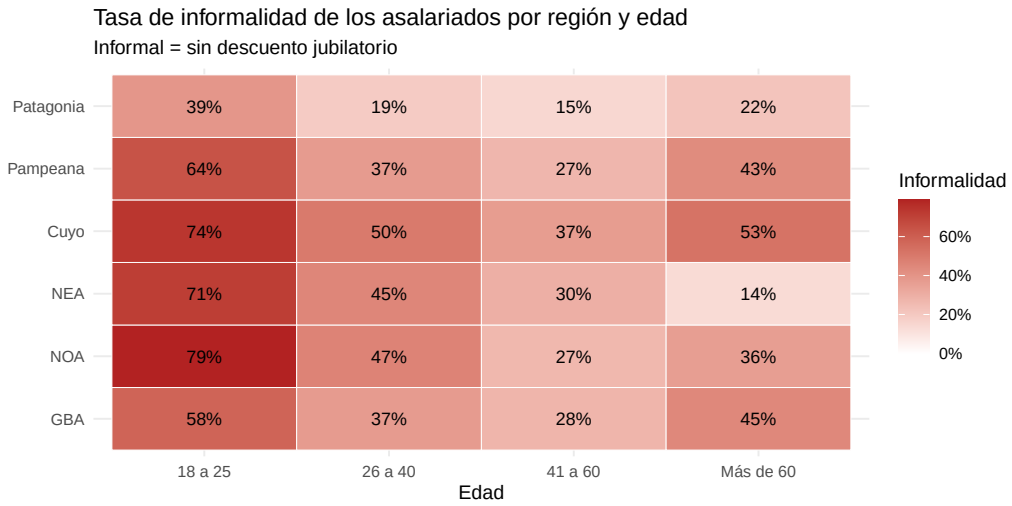


Figura 5: Tasa de informalidad de los asalariados por región y tramo de edad.

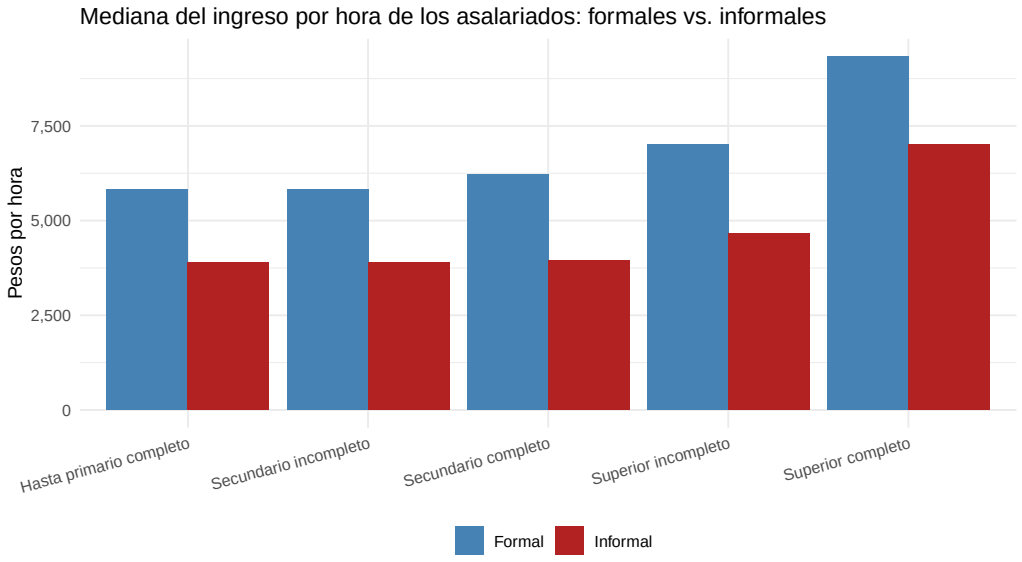


Figura 6: Mediana del ingreso por hora de asalariados formales e informales, por nivel educativo.

Nivel educativo	Formal ($/hora)	Informal ($/hora)	Penalidad
Hasta primario completo	5,833	3,889	33.3 %
Secundario incompleto	5,833	3,889	33.3 %
Secundario completo	6,222	3,941	36.7 %
Superior incompleto	7,000	4,667	33.3 %
Superior completo	9,333	7,000	25.0 %
Todos	7,000	4,242	39.4 %

Más de un tercio de los asalariados (37.9 %) es informal: trabaja en relación de dependencia pero sin aportes jubilatorios ni, en general, el resto de la protección laboral.

Edad. La informalidad tiene forma de U: es altísima entre los jóvenes (62 % entre 18 y 25 años), cae a un mínimo de 28 % entre los 41 y 60 años y vuelve a subir después de los 60 (42 %). Es consistente con trayectorias en las que se entra al mercado de trabajo por empleos precarios y se "formaliza" con la experiencia, y con la reinserción informal de quienes ya se jubilaron.

Región. Hay una fuerte heterogeneidad geográfica: Cuyo, el NOA y el NEA superan el 41 %,

mientras que en la Patagonia la informalidad es menos de la mitad (20 %). El mapa de calor muestra que el gradiente por edad está presente en todas las regiones, y que es entre los jóvenes del NOA y Cuyo donde la informalidad es más alta (79 % y 74 %).

Educación y sexo. La informalidad cae fuertemente con la educación (de entre 51 % y 70 % sin secundario completo a 15–17 % con título universitario). En los niveles educativos bajos y medios, las mujeres son mucho más informales que los varones (70 % vs. 58 % con secundario incompleto), probablemente por su peso en el servicio doméstico, un sector con muy alta informalidad. Con título universitario la diferencia casi desaparece.

Penalidad salarial. A igual nivel educativo, un asalariado informal gana por hora entre un 25 % y un 37 % menos que uno formal. La penalidad agregada (39 %) es mayor que la de cada nivel por un efecto composición: los informales están sobrerrepresentados en los niveles educativos bajos. Es decir, los informales no sólo carecen de protección social, sino que además cobran menos por hora. Como la comparación es descriptiva, la penalidad puede reflejar también diferencias de sector, tamaño de empresa o productividad que no observamos.

1.4. P3: Desigualdad del ingreso per cápita familiar por región

Código: `script_principal.R: Pregunta 3; funciones.R: gini_ponderado(), curva_lorenz()`

Universo: personas que viven en hogares que declararon sus ingresos (31,906 casos, que representan 30.1 millones de personas). Ponderador: `PONDIH`. Medimos la desigualdad con el coeficiente de Gini y con el cociente entre los percentiles 90 y 10.

Gini ponderado. Ordenando a las personas por IPCF de menor a mayor, con pesos normalizados w_i ($\sum w_i = 1$), la curva de Lorenz en la persona i es $L_i = \sum_{j \le i} w_j x_j / \sum_j w_j x_j$. El área bajo la curva se aproxima con trapecios, $A = \sum_i w_i (L_i + L_{i-1})/2$, y el Gini es $G = 1 - 2A = 1 - \sum_i w_i (L_i + L_{i-1})$. *Validación:* el Gini nacional que obtenemos, 0.442, coincide con el valor oficial publicado por el INDEC para el primer trimestre de 2026 (0.442), lo que confirma que la limpieza y la ponderación son correctas.

Región	Población (M)	IPCF medio	IPCF mediano	Mediana rel. al país	P90/P10	Gini
GBA	16.23	780,332	520,000	1.04	8.06	0.458
Patagonia	1.15	915,730	666,667	1.33	6.92	0.416
NEA	1.49	482,231	363,875	0.73	7.06	0.415
Pampeana	6.46	743,305	551,667	1.10	7.08	0.414
Cuyo	1.89	573,696	419,000	0.84	5.34	0.388
NOA	2.88	551,554	422,000	0.84	5.45	0.383
Total país	30.10	728,008	500,000	1.00	7.50	0.442

IPCF en pesos corrientes por mes, primer trimestre de 2026.

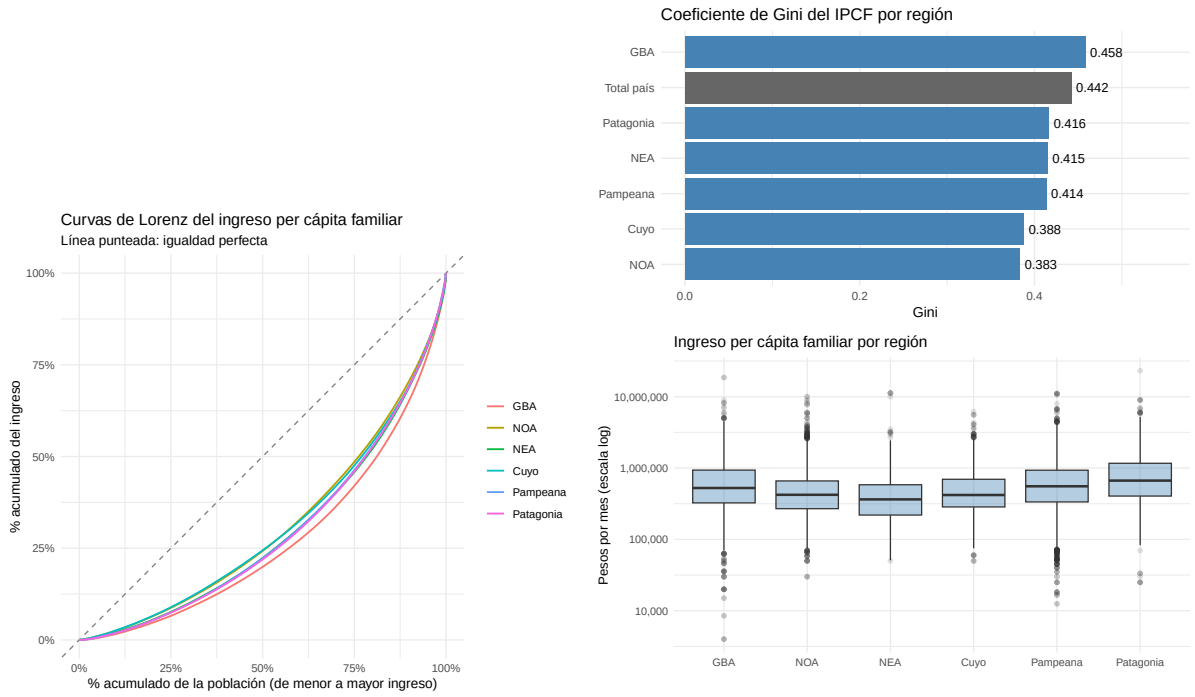


Figura 7: Curvas de Lorenz por región (izquierda), Gini por región y distribución del IPCF (derecha).

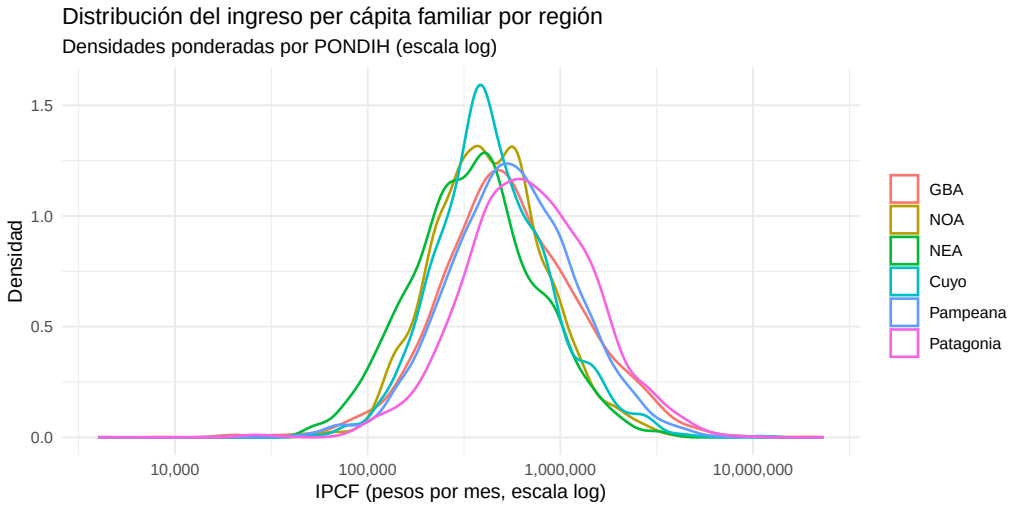


Figura 8: Densidades del IPCF por región (escala logarítmica, ponderadas por `PONDIH`).

El Gran Buenos Aires es la región más desigual (Gini 0.458; el percentil 90 del ingreso por persona es 8.1 veces el percentil 10). Su curva de Lorenz queda por debajo de las del resto. Le sigue un grupo intermedio, con Gini de alrededor de 0.415 (Patagonia, NEA y Pampeana), y las regiones menos desiguales son Cuyo y el NOA (Gini por debajo de 0.39 y cociente P90/P10 de alrededor de 5.4).

Nivel y desigualdad no van de la mano. La Patagonia tiene el ingreso mediano más alto (33 % por encima del total del país) y desigualdad intermedia. El NEA tiene el ingreso mediano más bajo (27 % por debajo del total) y, aun así, una desigualdad similar a la de la Patagonia. El NOA y Cuyo, con ingresos 16 % por debajo del total, son los menos desiguales: sus distribuciones están más concentradas en ingresos medios-bajos (las densidades están corridas a la izquierda y son más "picudas"). El GBA tiene una mediana similar a la del país, pero colas más largas en

ambos extremos.

La desigualdad del país es mayor que la de cualquier región salvo el GBA. Como el total mezcla regiones con niveles de ingreso distintos, a la desigualdad *dentro* de cada región se le suma la desigualdad *entre* regiones. Además, el GBA concentra más de la mitad de la población representada (54 %), así que pesa mucho en el indicador nacional.

Limitaciones: los ingresos están en pesos corrientes y no se ajustan por diferencias de costo de vida entre regiones (más alto en la Patagonia), y la EPH sólo cubre aglomerados urbanos. Además, el ingreso declarado en encuestas suele subestimar los ingresos altos, por lo que la desigualdad real probablemente sea mayor.

Fuente de la validación. Gini oficial del IPCF para el 1er trimestre de 2026 (0.442), informado por el INDEC; ver, por ejemplo, Chequeado, "Creció la desigualdad en la Argentina en el primer trimestre de 2026, según el INDEC", `https://chequeado.com/nota/crecio-la-desigualdad-en-la-argentina-en-el-primer-trimestre-de-2026-segun-el-indec`.

2. Análisis econométrico con datos de *gapminder*

El código está en `analisis_econometrico/`: `funciones.R` define las funciones de limpieza, ajuste, evaluación y gráficos; `script_principal.R` resuelve cada inciso en orden. Los datos (`gapminder.csv`) están en `analisis_econometrico/data/`.

Carga, limpieza y chequeos previos

Código: `funciones.R: cargar_gapminder(); script_principal.R: sección 0`

El archivo tiene 9,843 filas: un panel balanceado de 193 países × 51 años (1960–2010), sin duplicados país–año. Antes de modelar revisamos tipos y faltantes, y encontramos tres problemas que corregimos en `cargar_gapminder()`:

- `life_expectancy_female` se leía como *texto*, porque los faltantes estaban codificados con un guion `"-"`. Los tratamos como `NA` y convertimos la columna a numérica.
- `life_expectancy_male` usaba `-999` como código de faltante (lo que llevaba su media a 10.6 años). Lo recodificamos como `NA`.
- `main_religion` tenía categorías duplicadas por mayúsculas y espacios (`"muslim"`/`"Muslim"`, `"eastern religions"`). Las normalizamos.

Después de la limpieza, los faltantes de esperanza de vida se concentran en 9 microestados (Andorra, Dominica, Islas Marshall, Mónaco, Nauru, Palau, San Marino, St. Kitts y Nevis, Tuvalu). Ninguno es sudamericano, así que la Parte 1 usa series completas. En la Parte 2 trabajamos con los 184 países con datos completos.

Parte 1: Ingreso por persona

2.1. Evolución del ingreso por persona en Argentina

Código: `script_principal.R: Parte 1 - Inciso 1`

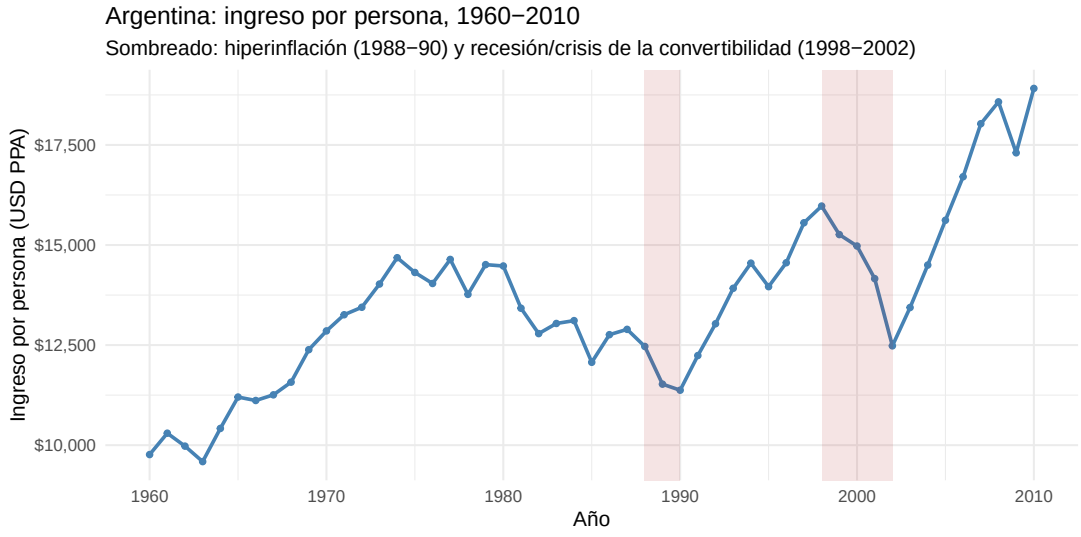


Figura 9: Ingreso por persona de Argentina, 1960–2010.

El ingreso por persona casi se duplica en 50 años (de 9,765 en 1960 a 18,912 en 2010), pero a una tasa anual compuesta de sólo 1.33 %, y con una trayectoria muy volátil, de tipo *stop and go*:

- 1960–1974: crecimiento sostenido, hasta ≈14,700.

- 1975–1990: estancamiento y caída (crisis de la deuda, hiperinflación). En 1990 el ingreso (11,373) era menor que en 1970.
- 1991–1998: recuperación durante la convertibilidad, con un pico de 15,973.
- 1999–2002: recesión y crisis de 2001–2002. En 2002 se registra la peor caída anual de la serie ($-11.9\,\%$).
- 2003–2010: fuerte rebote (con una caída en 2009, $-6.9\,\%$, por la crisis internacional), hasta máximos históricos.

La tendencia de largo plazo es creciente, pero los desvíos alrededor de ella son grandes y persistentes, lo que anticipa que una función suave del tiempo va a ajustar mal.

2.2. Regresiones sobre el tiempo y evaluación fuera de la muestra

Código: `funciones.R: ajustar_polinomio(), evaluar_modelos(); script_principal.R: Parte 1 - Inciso 2`

Definimos t = año $-$ 1960. Separamos los últimos 10 años (2001–2010) como conjunto de testeo y estimamos con 1960–2000 (41 observaciones) los tres modelos pedidos:

$$\text{(a)} \quad \text{income}_t = \beta_0 + \beta_1 t + \varepsilon_t$$
$$\text{(b)} \quad \text{income}_t = \beta_0 + \beta_1 t + \beta_2 t^2 + \varepsilon_t$$
$$\text{(c)} \quad \text{income}_t = \beta_0 + \beta_1 t + \beta_2 t^2 + \cdots + \beta_{10} t^{10} + \varepsilon_t$$

Estimamos con `poly(t, grado)`, que usa una base ortogonal en lugar de potencias crudas. Como vimos en clase, ambas generan el mismo subespacio y producen *exactamente las mismas predicciones* (lo verificamos con `stopifnot()` en el modelo cuadrático). La base ortogonal evita los problemas numéricos de calcular t^{10} con t hasta 50. Los coeficientes del cuadrático en potencias crudas son $\hat{\beta}_0 = 10{,}358$, $\hat{\beta}_1 = 206.1$ y $\hat{\beta}_2 = -2.83$.

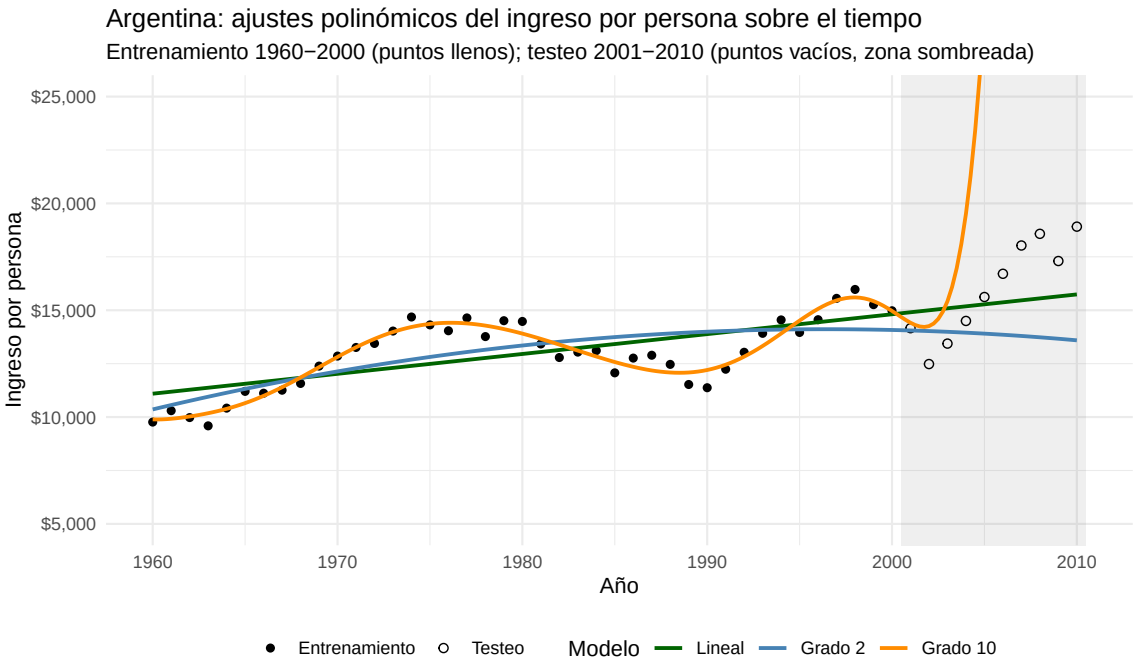


Figura 10: Datos observados y los tres ajustes. La zona sombreada es el período de testeo (el eje vertical está recortado: el polinomio de grado 10 sale del gráfico).

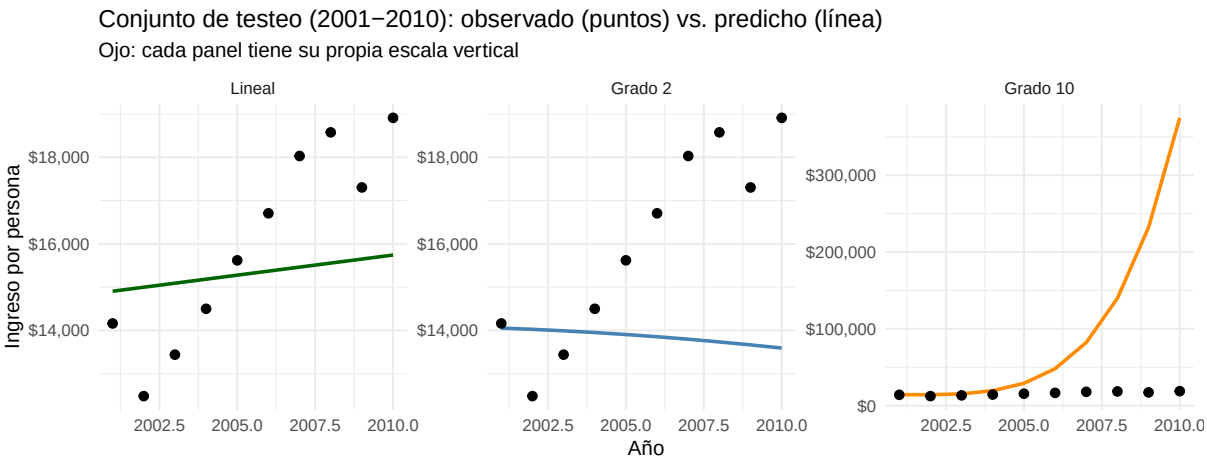


Figura 11: Conjunto de testeo: valores observados (puntos) y predicciones de cada modelo (cada panel con su escala).

	Entrenamiento (1960–2000)		Testeo (2001–2010)		
Modelo	R^2	RMSE	RMSE	MAE	MAPE
Lineal	0.451	1,213	2,012	1,769	10.9 %
Grado 2	0.498	1,160	3,114	2,535	14.8 %
Grado 10	0.943	393	138,837	81,005	447.2 %

Predicción para 2010 (observado: 18,912): lineal 15,741; grado 2 13,591; grado 10 374,699.

Dentro de la muestra, a más grado, mejor ajuste: el R^2 pasa de 0.45 (lineal) a 0.50 (cuadrático) y 0.94 (grado 10). El polinomio de grado 10 sigue casi todos los ciclos de la serie. El cuadrático capta una leve concavidad ($\hat{\beta}_2 < 0$), que refleja el estancamiento de los 80.

Fuera de la muestra, el orden se invierte por completo:

- El grado 10 es un caso de manual de *overfitting*: ajusta el ruido del entrenamiento y, al extrapolar, los términos de alto orden dominan y la predicción explota (predice casi 375,000 para 2010, 20 veces el valor real; MAPE de 447 %).
- El cuadrático extrapola su concavidad y predice un ingreso *decreciente* justo cuando Argentina crece fuerte; queda segundo.
- El lineal, el más simple y con peor R^2 de entrenamiento, es el que mejor predice (error medio de 10.9 %). Aun así, subestima sistemáticamente desde 2005, porque ninguna tendencia determinística anticipa un rebote como el de 2003–2010.

Conclusión: el R^2 dentro de la muestra no sirve para elegir modelos de pronóstico; hay que evaluar en datos no usados para estimar. Además, una regresión sobre el tiempo describe una tendencia, pero no modela los determinantes del ingreso: con una serie tan volátil, cualquier extrapolación a 10 años tiene errores grandes.

2.3. Correlaciones con otros países sudamericanos

Código: `funciones.R: a_formato_ancho(), crecimiento_interanual(), graficar_correlaciones(); script_principal.R: Parte 1 - Inciso 3`

Elegimos Brasil, Chile, Uruguay y Venezuela: los tres primeros son los principales socios regionales de Argentina; Venezuela, una economía petrolera con una dinámica muy distinta, sirve de contraste. Calculamos (a) la correlación entre los *niveles* de ingreso por persona y (b) la correlación entre los crecimientos interanuales $\Delta Y_t / Y_{t-1}$ (1961–2010).

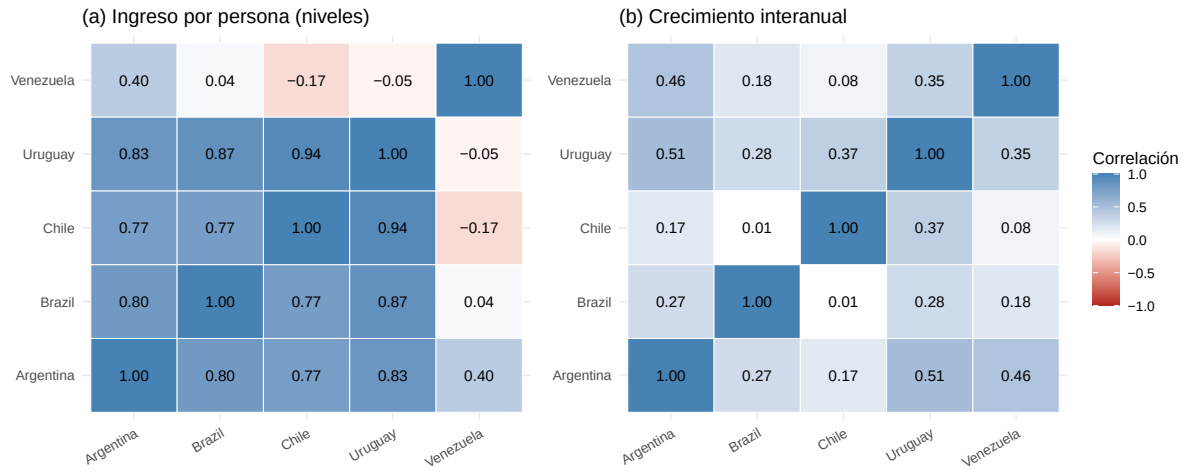


Figura 12: Matrices de correlación: niveles de ingreso (izquierda) y crecimiento interanual (derecha).

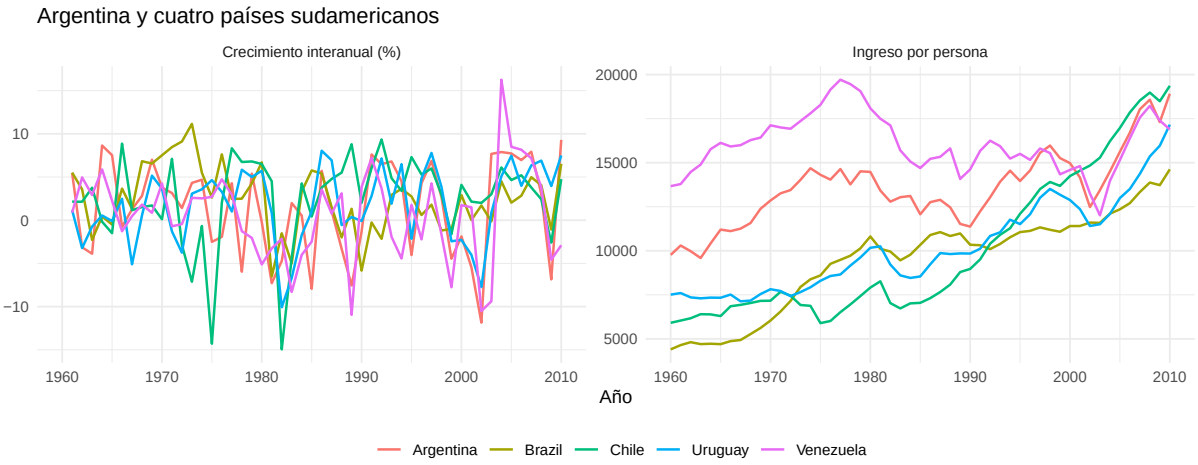


Figura 13: Ingreso por persona y crecimiento interanual de los cinco países.

	(a) Niveles					(b) Crecimiento interanual				
	ARG	BRA	CHL	URY	VEN	ARG	BRA	CHL	URY	VEN
ARG	1	0.80	0.77	0.83	0.40	1	0.27	0.17	0.51	0.46
BRA		1	0.77	0.87	0.04		1	0.01	0.28	0.18
CHL			1	0.94	−0.17			1	0.37	0.08
URY				1	−0.05				1	0.35
VEN					1					1

Crecimiento medio anual (desvío): ARG 1.5 % (5.4 %), BRA 2.5 % (3.8 %), CHL 2.5 % (5.0 %), URY 1.8 % (4.3 %), VEN 0.6 % (5.2 %).

Niveles. Las correlaciones entre Argentina, Brasil, Chile y Uruguay son muy altas (0.77 a 0.94), pero dicen poco sobre la relación económica entre los países: las cuatro series tienen *tendencia creciente*, y dos series con tendencia están muy correlacionadas aunque no tengan nada que ver (correlación espuria por no estacionariedad). La excepción confirma la regla: Venezuela, cuyo ingreso se estancó y cayó desde fines de los 70 mientras los demás crecían, tiene correlación nula o negativa con todos.

Crecimiento. Al diferenciar quitamos la tendencia común y medimos si los países se mueven juntos *año a año*. Las correlaciones caen mucho (entre 0.01 y 0.51), aunque son todas positivas, lo que sugiere shocks comunes moderados (precios de materias primas, condiciones financieras internacionales, la crisis de la deuda de los 80). La relación más fuerte de Argentina es con Uruguay (0.51), consistente con la integración rioplatense y con crisis compartidas (1982, 2002). Le sigue Venezuela (0.46), algo que no aparecía en niveles y que sugiere shocks comunes de corto plazo (por ejemplo, la crisis de la deuda de los 80), aunque las tendencias de largo plazo hayan sido opuestas. Chile y Brasil, en cambio, tienen ciclos casi independientes ($\rho = 0.01$).

En síntesis, la similitud de largo plazo (niveles) no implica ciclos sincronizados (crecimiento), y la volatilidad del crecimiento argentino (5.4 %) es la más alta del grupo.

Parte 2: Esperanza de vida y género

Año elegido: 2010, el más reciente del panel. Usamos los 184 países con datos completos de esperanza de vida total, femenina e ingreso.

Un hallazgo de los datos. Por definición, la esperanza de vida total es un promedio de la femenina y la masculina, así que debería estar *entre* ambas. Sin embargo, en 2010 la femenina es *menor* que la total en el 20 % de los países (por ejemplo, Nigeria: total 60.5, femenina 51.7, masculina 50.2). Esto indica que la variable total y las variables por sexo provienen de fuentes o metodologías distintas. Además, Haití muestra una esperanza de vida total de 32.5 años en 2010 (61.5 en 2009), por el terremoto de ese año, mientras que la femenina (62.5) no refleja el shock. Lo tenemos en cuenta al interpretar los resultados.

5. Esperanza de vida total vs. femenina

Código: `script_principal.R: Inciso 5`

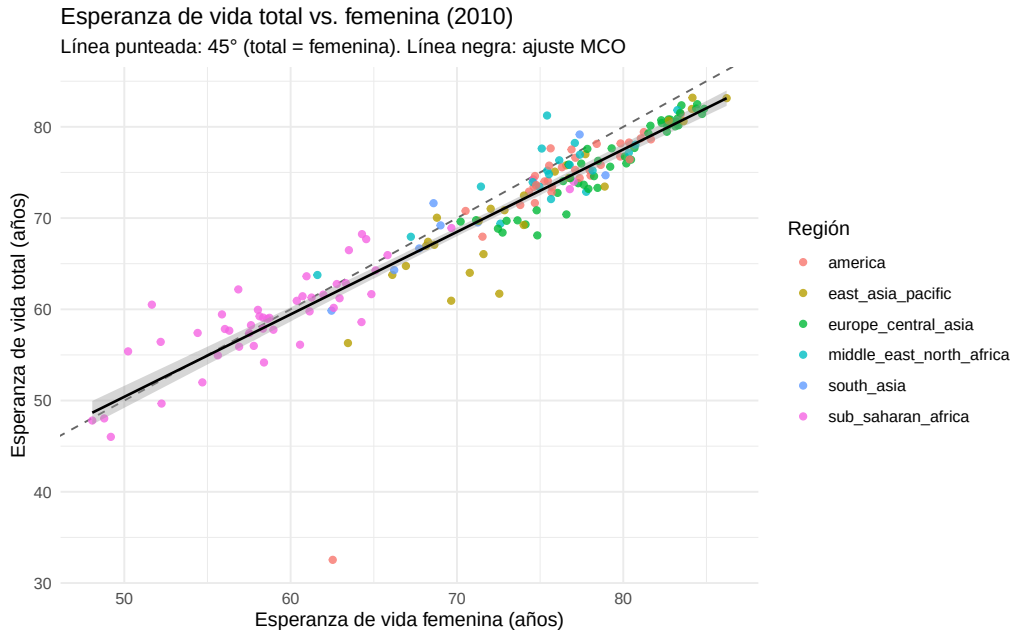


Figura 14: Esperanza de vida total vs. femenina por país (2010).

La relación es positiva, fuertemente lineal y muy estrecha (correlación 0.935): los países donde las mujeres viven más son los países donde la población en general vive más. Casi todos los puntos quedan *debajo* de la recta de 45°, es decir, la esperanza de vida femenina supera a la total (las mujeres viven más que los hombres). La distancia a la recta de 45° crece levemente

en los países de mayor esperanza de vida. Hay un outlier evidente: Haití (abajo, al centro). Los países de África subsahariana se concentran en la zona baja.

6. Regresión simple

Código: `script_principal.R: Inciso 6; funciones.R: tabla_coeficientes(), r2_manual(), test_t_coeficiente()`

$$\widehat{\text{life_exp}}_i = \underset{(1.85)}{5.22} + \underset{(0.025)}{0.904}\ \text{life_exp_female}_i, \qquad n = 184, \quad R^2 = 0.874$$

- $\hat{\beta}_1 = 0.904$, IC 95 %: $[0.854,\ 0.954]$; $t = 35.6$, p-valor $< 10^{-80}$.
- $R^2 = 0.8743$ (igual al calculado a mano como $1 - SS_{res}/SS_{tot}$, y a $\rho^2 = 0.935^2$, como corresponde en la regresión simple).
- Test de $H_0 : \beta_1 = 1$: $t = (0.904 - 1)/0.025 = -3.79$, p-valor $= 0.0002$.

Coeficiente. Comparando países, un año más de esperanza de vida femenina está asociado, en promedio, a 0.90 años más de esperanza de vida total. El coeficiente es altamente significativo y *significativamente menor que 1*. Si la brecha de género fuera la misma en todos los países, esperaríamos una pendiente de 1 (las dos variables se moverían uno a uno). Que sea menor indica que la brecha entre la esperanza de vida femenina y la total crece con el nivel de desarrollo: en los países donde se vive más, las mujeres le sacan más ventaja a los hombres. También pueden contribuir el error de medición (las diferencias de fuente señaladas arriba), que atenúa la pendiente hacia 0, y outliers como Haití. Sin Haití, $\hat{\beta}_1 = 0.886$.

R^2. La esperanza de vida femenina "explica" el 87 % de la variabilidad de la esperanza de vida total entre países (93 % sin Haití). Qué implica: el ajuste es altísimo, pero es casi *mecánico*. La total es un promedio ponderado de la femenina y la masculina, que a su vez están muy correlacionadas: estamos explicando una variable con otra que es, en buena medida, ella misma. El resultado es útil para predecir (si conozco una, conozco la otra), pero no tiene interpretación causal ni dice nada sobre los *determinantes* de la esperanza de vida. Por eso el inciso 9 la excluye.

7. Test de hipótesis: ¿la esperanza de vida femenina es mayor?

Código: `script_principal.R: Inciso 7`

Planteo del test. Las dos variables se miden en el mismo país, así que las observaciones están *apareadas*. Trabajamos con la diferencia $d_i = \text{female}_i - \text{total}_i$ y contrastamos

$$H_0 :\ \mu_d = 0 \qquad \text{vs.} \qquad H_1 :\ \mu_d > 0, \qquad t = \frac{\bar{d}}{s_d/\sqrt{n}} \overset{H_0}{\sim} t_{n-1}.$$

El test es unilateral a derecha: rechazamos H_0 si $t > t_{n-1,\,0.95}$. Es equivalente a regresar d_i sobre una constante (`lm(dif ~ 1)`) y testear si la constante es positiva; lo hicimos de las dos formas y dan lo mismo. Como chequeo de robustez, que no supone normalidad, corrimos también el test de rangos con signo de Wilcoxon.

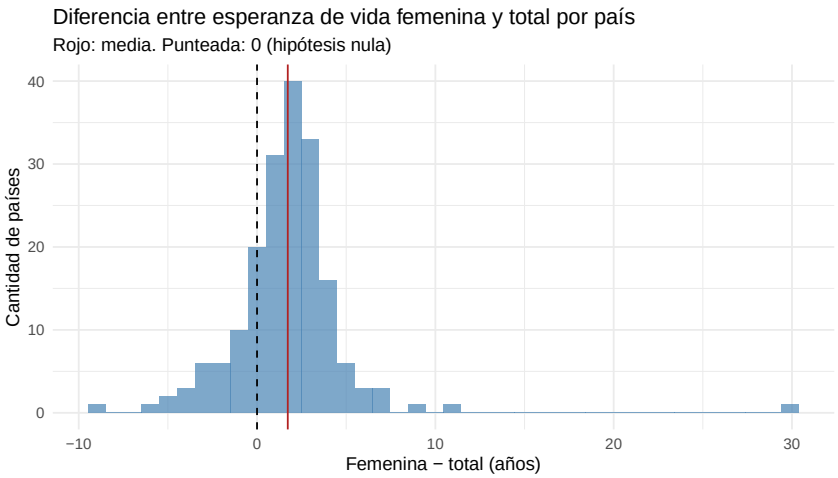


Figura 15: Distribución de d_i = esperanza de vida femenina − total, por país (2010).

- $\bar{d} = 1.72$ años, $s_d = 3.29$, $n = 184$.
- $t = 7.11$ con 183 g.l.; p-valor unilateral $= 1.3 \times 10^{-11}$.
- Cota inferior del IC 95 % unilateral: $\mu_d \geq 1.32$ años.
- Wilcoxon (unilateral): p-valor $= 1.9 \times 10^{-15}$.

Rechazamos H_0 con mucha holgura: hay evidencia empírica fuerte de que la esperanza de vida femenina es mayor que la total; en promedio, 1.7 años más (al menos 1.3 con 95 % de confianza). Es consistente con el hecho, muy documentado, de que las mujeres viven más que los hombres. Dos matices: (i) la evidencia es sobre el *promedio* entre países, y en el 20 % de ellos la diferencia observada es negativa, algo que, como discutimos, se debe más a la inconsistencia entre fuentes que a una ventaja real de los hombres; (ii) la distribución de d_i tiene colas pesadas (Haití: +30 años), pero el test de Wilcoxon, que no depende de la normalidad ni es sensible a outliers, lleva a la misma conclusión.

8. Regresión múltiple con ingreso por persona

Código: `script_principal.R: Inciso 8`

$$\widehat{\text{life_exp}}_i = \underset{(2.11)}{7.40} + \underset{(0.031)}{0.866}\ \text{life_exp_female}_i + \underset{(1.54\times10^{-5})}{3.20\times10^{-5}}\ \text{income}_i$$

	Simple (inc. 6)	Múltiple (inc. 8)	Múltiple sin Haití
Coef. life_exp_female	0.904	0.866	0.851
Coef. income (por cada 10,000)	–	0.32 (p = 0.039)	(p = 0.009)
R^2	0.8743	0.8772	0.929
R^2 ajustado	0.8736	0.8759	–

Test F de modelos anidados (agregar income): $F = 4.32$, p-valor $= 0.039$. Correlación entre regresores: $\rho(\text{female}, \text{income}) = 0.58$.

Coeficientes. (i) *Esperanza de vida femenina*: entre países con el mismo ingreso por persona, un año más de esperanza de vida femenina se asocia a 0.87 años más de esperanza de vida total. (ii) *Ingreso*: entre países con la misma esperanza de vida femenina, 10,000 dólares más de ingreso por persona se asocian a 0.32 años más de esperanza de vida total. El efecto es significativo al 5 % pero pequeño (el desvío del ingreso entre países es ≈19,000).

Qué pasa con la relación esperanza de vida–género. Al controlar por ingreso, el coeficiente de la esperanza de vida femenina baja de 0.904 a 0.866. Es el sesgo de variable omitida visto en

clase: el ingreso está positivamente correlacionado con la esperanza de vida femenina (0.58) y con la total, así que en la regresión simple parte del "efecto" del ingreso se le atribuía a la variable femenina. Pero el cambio es chico: la relación sigue siendo casi uno a uno y muy significativa. Era de esperar, porque la relación es casi mecánica y no pasa por el ingreso.

¿Vale la pena incluir el ingreso? El R^2 sube apenas de 0.874 a 0.877 (y el R^2 ajustado, que penaliza el regresor extra, de 0.8736 a 0.8759). El test F rechaza al 5 % que el aporte sea nulo. Desde lo estadístico se justifica marginalmente; en la práctica, agrega muy poco poder explicativo, porque la esperanza de vida femenina ya captura casi toda la información sobre el nivel de desarrollo del país. Además, el ingreso en niveles impone una relación lineal que no es la adecuada: la relación entre esperanza de vida e ingreso es claramente cóncava (ver inciso 9). Si el objetivo es entender la asociación con el ingreso controlando por género, conviene incluirlo; si el objetivo es predecir, la mejora es marginal.

9. Selección de un modelo con hasta tres covariables

Código: `script_principal.R: Inciso 9; funciones.R: comparar_subconjuntos()`

Seguimos estos pasos:

Paso 1: qué excluir y por qué.

- `life_expectancy_female` (lo pide la consigna) y `life_expectancy_male`: la total es, por construcción, un promedio de ambas, así que incluir la masculina repetiría el problema de "explicar la variable con ella misma".
- `country`: identificador (una observación por país en el corte de 2010).
- `year`: es constante en el corte transversal.
- `income_groups`: es una discretización del ingreso (redundante y con pérdida de información).
- `world_region` y `main_religion`: categóricas con 6 y 3 niveles; cada nivel usaría una de las tres covariables permitidas, y la religión además tiene faltantes. De la región rescatamos una sola *dummy*, `africa_subsahariana`, porque es la región con un comportamiento claramente distinto (ver el gráfico del inciso 5).

Paso 2: construir candidatas (columnas nuevas). log(income), log(child_mortality), log(population), `oecd` (0/1) y `africa_subsahariana` (0/1), además de las originales.

Paso 3: ¿niveles o logaritmos? Comparamos gráficamente y por correlación cada variable en niveles y en logaritmos, con una recta MCO y un suavizado *loess* para detectar no linealidades.

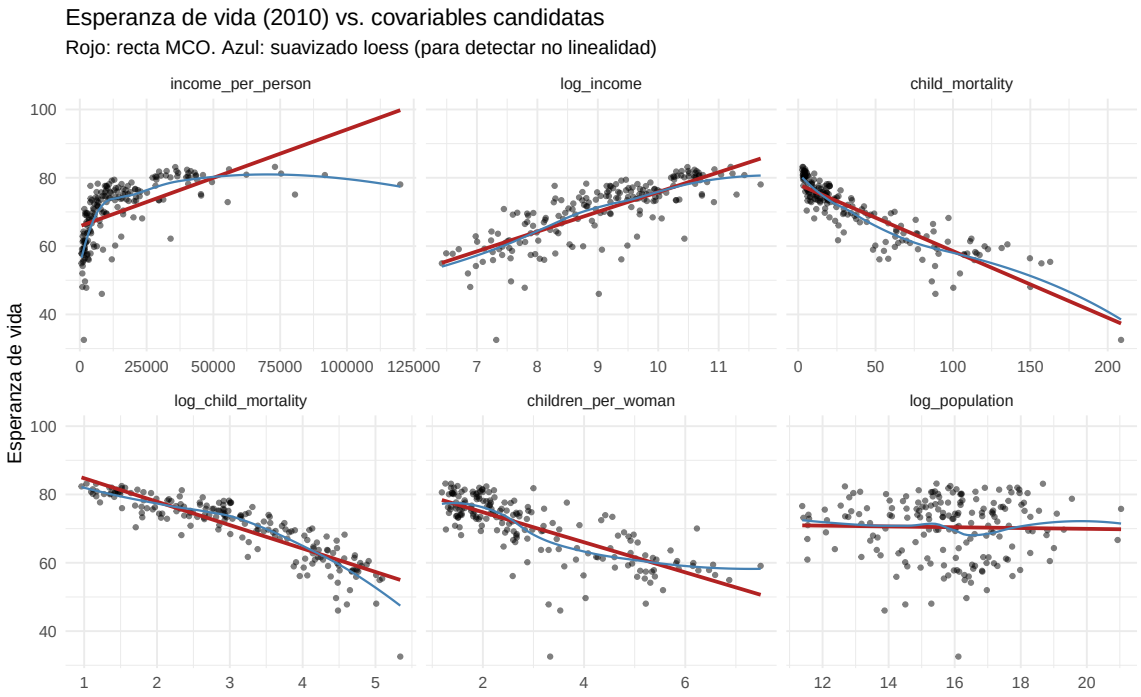


Figura 16: Esperanza de vida vs. cada candidata (2010). Rojo: recta MCO; azul: loess.

Correlación con la esperanza de vida: income 0.59 vs. log(income) 0.78; child_mortality −0.89 vs. log(child_mortality) −0.88; children_per_woman −0.75; log(population) −0.02; oecd 0.49; africa_subsahariana −0.70.

El ingreso en niveles tiene una relación fuertemente cóncava (rendimientos decrecientes: pasar de 1,000 a 5,000 dólares importa mucho más que pasar de 50,000 a 54,000), que el logaritmo linealiza; por eso usamos log(income). Para la mortalidad infantil ambas versiones tienen una correlación similar (−0.89 vs. −0.88); elegimos el logaritmo porque comprime la cola de valores altos (hay países con más de 150 muertes por cada mil nacidos) y reduce la influencia de esos pocos países sobre la recta. Nos quedan 6 candidatas: log(income), log(child_mortality), children_per_woman, log(population), oecd y africa_subsahariana.

Paso 4: multicolinealidad. Las variables de desarrollo están muy correlacionadas entre sí: log(income) y log(child_mortality), −0.85; log(child_mortality) y children_per_woman, 0.83. Esto anticipa que no tiene sentido incluir las tres juntas: aportan información parecida.

Paso 5: búsqueda exhaustiva con validación. Como vimos en clase con `wage1`, separamos los datos en entrenamiento (70 %) y testeo (30 %) y estimamos *todas* las combinaciones posibles de 1, 2 y 3 covariables entre las 6 candidatas ($6+15+20=41$ modelos). Para cada una calculamos R^2 y R^2 ajustado en entrenamiento y el error cuadrático medio (ECM) en testeo.

Mejor modelo de cada tamaño (por ECM de testeo)	R^2	R^2 aj.	ECM test
log(child_mortality)	0.765	0.763	15.6
log(child_mortality) + africa_subsahariana	0.784	0.781	13.5
log(income) + log(child_mortality) + africa_subsahariana	0.787	0.782	12.9

Referencias: sólo log(income): ECM 17.9; sólo log(population): ECM 72.0.
Mayor R^2 aj. en entrenamiento (log(cm) + children + africa, 0.789) tiene ECM test 15.6.

Paso 6: modelo elegido, reestimado con los 184 países:

$$\widehat{\text{life_exp}}_i = \underset{(5.64)}{78.32} + \underset{(0.470)}{0.935}\ \log(\text{income}_i) - \underset{(0.547)}{4.961}\ \log(\text{child_mort}_i) - \underset{(0.931)}{4.050}\ \text{africa_ss}_i$$

$$n = 184, \qquad R^2 = 0.796, \qquad \bar{R}^2 = 0.792$$

Paso 7: diagnóstico.

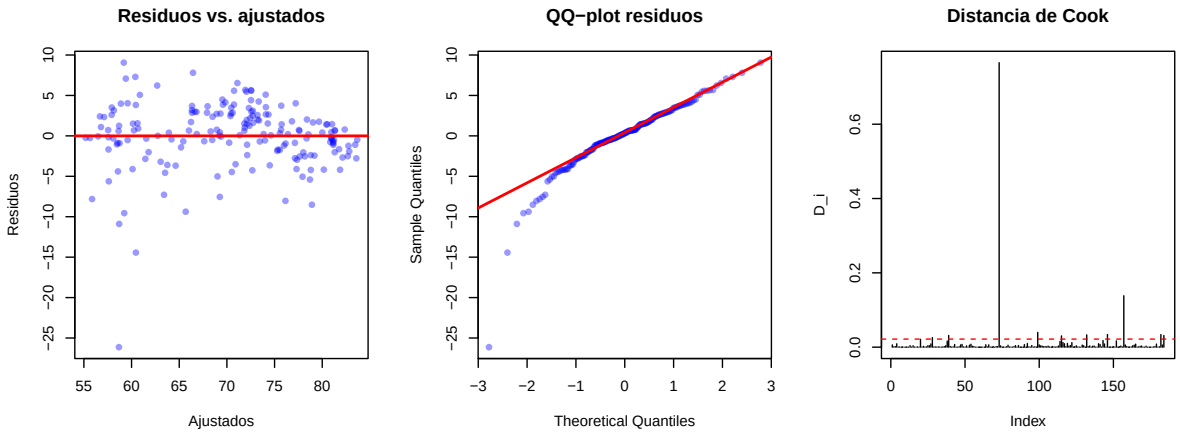


Figura 17: Diagnóstico del modelo elegido: residuos vs. ajustados, QQ-plot y distancia de Cook.

- VIF: log(income) 3.5, log(child_mortality) 4.3, africa_ss 1.9. Todos menores a 5: no hay multicolinealidad grave.
- Breusch–Pagan: $BP = 11.8$, p-valor $= 0.008$: hay heterocedasticidad. Con errores estándar robustos HC3, los tres coeficientes siguen siendo significativos al 5 %: log(income) p $= 0.039$, log(child_mort.) p $< 10^{-8}$, africa_ss p $= 0.010$.
- Observación influyente: Haití (residuo -26 años, distancia de Cook 0.77). Sin Haití, $R^2 = 0.829$ y los coeficientes mantienen signo y significatividad (log(income) 1.02, log(child_mort.) -4.30, africa_ss -5.29).

Interpretación de los coeficientes (todo lo demás constante):

- *Ingreso*: un ingreso por persona 10 % mayor se asocia a $0.935 \times \ln(1.1) \approx 0.09$ años más de esperanza de vida. Duplicar el ingreso se asocia a $0.935 \times \ln 2 \approx 0.65$ años más.
- *Mortalidad infantil*: una mortalidad infantil 10 % mayor se asocia a $4.96 \times \ln(1.1) \approx 0.47$ años menos de esperanza de vida. Es, por lejos, la variable más explicativa: por sí sola explica el 76 % de la varianza. Parte de esa relación es mecánica (las muertes antes de los 5 años bajan directamente la esperanza de vida al nacer), pero también resume el acceso a la salud, el saneamiento y la nutrición.
- *África subsahariana*: a igual ingreso y mortalidad infantil, la esperanza de vida es 4 años menor. Esta dummy captura factores que las otras dos variables no explican, como la epidemia de VIH/SIDA en el sur de África (Eswatini y Lesotho están entre los residuos más grandes).

Por qué este modelo. Es el de menor error de predicción fuera de la muestra entre los 41 candidatos, su R^2 ajustado (0.782) está entre los más altos, sus variables no son redundantes (VIF < 5) y cada coeficiente tiene un signo e interpretación económica razonables. Notar que el modelo con mayor R^2 ajustado en entrenamiento no es el que mejor predice: otra vez, ajustar bien dentro de la muestra no alcanza. Limitaciones: la diferencia de ECM con el mejor modelo de 2 covariables es chica (12.9 vs. 13.5) y el conjunto de testeo es pequeño ($\approx$55 países), así que la ventaja del tercer regresor es modesta. Son asociaciones de corte transversal, no efectos causales.

3. Simulación: demanda con preferencias Cobb–Douglas

Todo el código está en `simulacion/`: las funciones pedidas (`simular_ingreso`, `demanda_cd`, `prob_bajo_consumo`) y auxiliares están en `funciones.R`; `script_principal.R` las ejecuta inciso por inciso.

Marco teórico

Demandas marshallianas y utilidad indirecta. El hogar resuelve $\max_{x_1,x_2} x_1^{\alpha_1} x_2^{\alpha_2}$ sujeto a $p_1x_1 + p_2x_2 \leq Y$. Como la utilidad es estrictamente creciente, la restricción se cumple con igualdad. Tomando logaritmos (transformación monótona, mismo óptimo):

$$\mathcal{L} = \alpha_1 \ln x_1 + \alpha_2 \ln x_2 + \lambda\,(Y - p_1x_1 - p_2x_2).$$

Condiciones de primer orden:

$$\frac{\alpha_1}{x_1} = \lambda p_1, \qquad \frac{\alpha_2}{x_2} = \lambda p_2 \quad \Longrightarrow \quad p_j x_j = \frac{\alpha_j}{\lambda}.$$

Sumando y usando la restricción: $Y = p_1x_1 + p_2x_2 = (\alpha_1 + \alpha_2)/\lambda = 1/\lambda$. Entonces

$$\boxed{x_1^* = \frac{\alpha_1 Y}{p_1}, \qquad x_2^* = \frac{\alpha_2 Y}{p_2}} \qquad \text{y} \qquad U^* = V(p_1, p_2, Y) = Y \left(\frac{\alpha_1}{p_1}\right)^{\alpha_1} \left(\frac{\alpha_2}{p_2}\right)^{\alpha_2}.$$

Tres propiedades que usamos todo el tiempo: (i) cada bien se lleva una fracción *fija* α_j del gasto; (ii) x_j^* y U^* son *lineales* en Y, así que heredan la forma de la distribución del ingreso; (iii) la elasticidad precio propia es $\partial \ln x_1^* / \partial \ln p_1 = -1$ y la cruzada es 0.

3.1. Generación de ingresos

Código: `simulacion/funciones.R: simular_ingreso(); script_principal.R: Inciso 1`

La función `simular_ingreso(n, k)` devuelve `rchisq(n, df = k)` tras chequear que n sea entero positivo y $k > 0$ (con `stop()` y mensajes informativos, como vimos en clase).

Momentos de $Y \sim \chi^2_k$ y cómo elegir k. Si $Y \sim \chi^2_k$:

$$E[Y] = k, \qquad \mathrm{Var}(Y) = 2k, \qquad \mathrm{CV}(Y) = \frac{\sqrt{2k}}{k} = \sqrt{\frac{2}{k}}, \qquad \text{Asimetría} = \sqrt{\frac{8}{k}}.$$

Un único parámetro fija a la vez el *nivel* y la *dispersión*. Por eso:

- Cómo elegir k: como $E[Y] = k$, k se elige para que el ingreso medio sea el deseado en las unidades monetarias que se usen.
- Qué pasa con la dispersión al subir k: la dispersión *absoluta* crece ($\sigma = \sqrt{2k}$), pero la *relativa* cae ($\mathrm{CV} = \sqrt{2/k} \to 0$) y la distribución se vuelve más simétrica (por el TCL, χ^2_k es una suma de k normales al cuadrado y tiende a la normal). En términos de desigualdad, más k implica una sociedad *más igualitaria*.

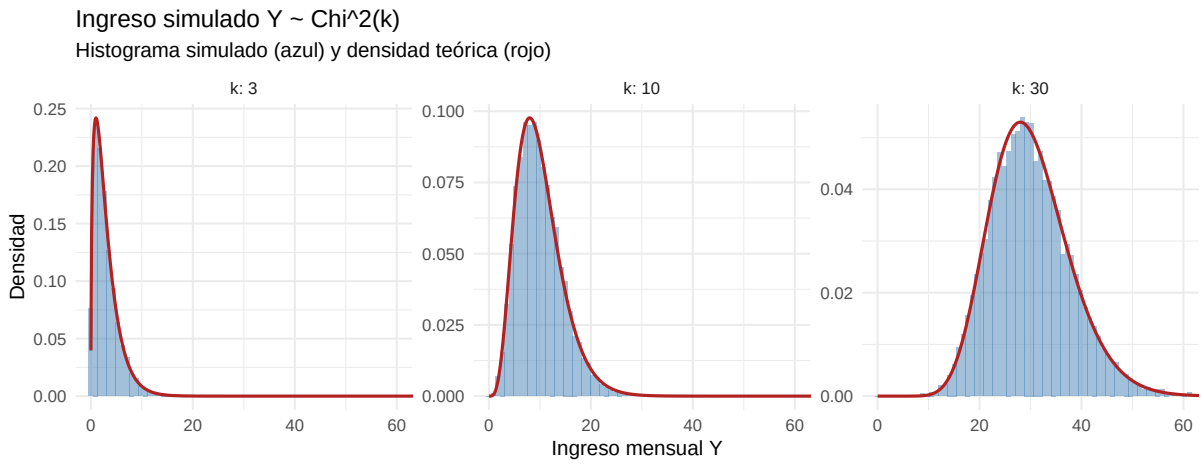


Figura 18: Ingresos simulados ($n = 10{,}000$) para $k \in \{3, 10, 30\}$ con la densidad teórica superpuesta.

k	Media sim.	Media teó.	Desvío sim.	Desvío teó.	CV sim.	CV teó.	Gini sim.
3	3.01	3	2.45	2.45	0.814	0.816	0.422
10	10.03	10	4.42	4.47	0.440	0.447	0.243
30	30.05	30	7.88	7.75	0.262	0.258	0.147

Los momentos simulados coinciden con los teóricos, lo que valida la función. Al pasar de $k = 3$ a $k = 30$ el desvío se triplica, pero el coeficiente de variación cae de 0.81 a 0.26 y el Gini de 0.42 a 0.15. Con $k = 3$ la distribución es muy asimétrica (muchos hogares de ingreso bajo y una cola larga de ingresos altos); con $k = 30$ ya es casi simétrica. Elegimos $k = 10$: ingreso medio de 10 unidades monetarias y dispersión intermedia (CV≈ 0.45), suficiente para que haya una masa no trivial de hogares de bajo consumo.

3.2. Demanda óptima Cobb–Douglas

Código: `simulacion/funciones.R: demanda_cd(); script_principal.R: Inciso 2`

```
demanda_cd <- function(Y, p1, p2, alpha1, alpha2) {
  if (any(Y <= 0))               stop("El ingreso Y debe ser positivo.")
  if (p1 <= 0 || p2 <= 0)        stop("Los precios deben ser positivos.")
  if (any(alpha1 <= 0 | alpha1 >= 1) || any(alpha2 <= 0 | alpha2 >= 1))
    stop("alpha1 y alpha2 deben estar en (0, 1).")
  if (any(abs(alpha1 + alpha2 - 1) > 1e-10))
    stop("alpha1 + alpha2 debe ser igual a 1.")
  x1 <- alpha1 * Y / p1
  x2 <- alpha2 * Y / p2
  U  <- x1^alpha1 * x2^alpha2
  tibble::tibble(x1 = x1, x2 = x2, U = U)
}
```

La función está *vectorizada*: `Y` y `alpha1` pueden ser vectores con un valor por hogar, lo que permite reutilizarla sin cambios en el inciso 7. Se verificó con un caso calculado a mano ($Y = 10$, $p_1 = 2$, $p_2 = 1$, $\alpha_1 = 0.4$: $x_1^* = 2$, $x_2^* = 6$, $U^* = 2^{0.4}6^{0.6} \approx 3.87$) y que el presupuesto se agota ($p_1 x_1^* + p_2 x_2^* = Y$), mediante `stopifnot()`.

3.3. Simulación base

Código: `simulacion/script_principal.R: Inciso 3`

Parámetros elegidos: $n = 10{,}000$ hogares, $k = 10$, $p_1 = 2$, $p_2 = 1$, $\alpha_1 = 0.4$, $\alpha_2 = 0.6$.

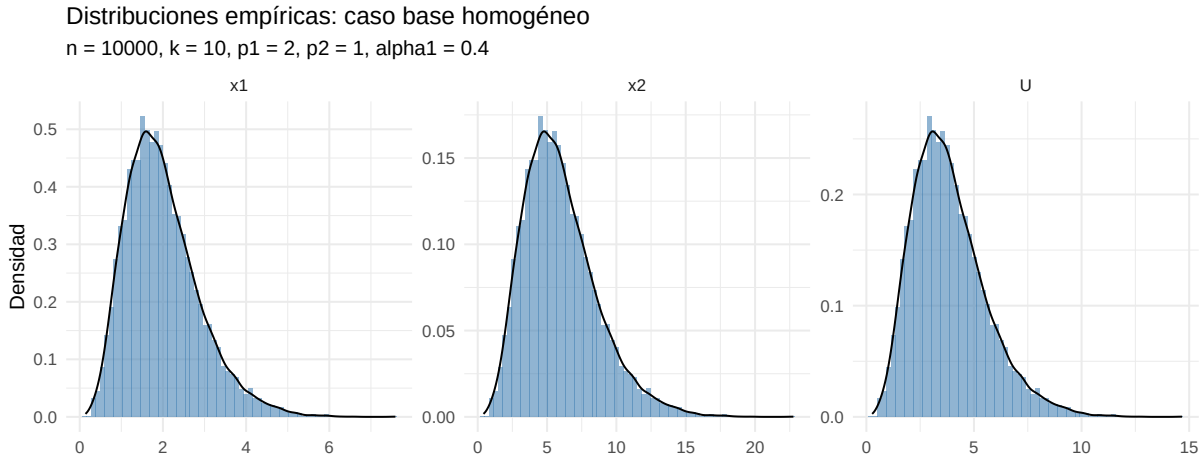


Figura 19: Distribuciones empíricas de x_1^*, x_2^* y U^* (histograma y densidad).

Variable	Media simulada	Media teórica	Q_1	Mediana	Q_3
x_1^*	1.991	2.000	1.349	1.864	2.489
x_2^*	5.972	6.000	4.046	5.591	7.467
U^*	3.848	3.866	2.607	3.603	4.812

Como x_j^* y U^* son múltiplos de Y, las tres distribuciones son χ^2_{10} reescaladas: tienen exactamente la misma forma asimétrica a la derecha que el ingreso. Las medias teóricas son $E[x_1^*] = \alpha_1 k/p_1 = 2$, $E[x_2^*] = \alpha_2 k/p_2 = 6$ y $E[U^*] = k(0.2)^{0.4}(0.6)^{0.6} \approx 3.87$; los cuartiles teóricos de x_1^* ($0.2\times$ los cuartiles de χ^2_{10}: 1.35, 1.87, 2.51) también coinciden con los simulados. La media supera a la mediana en las tres variables, típico de distribuciones con cola derecha.

3.4. Probabilidad de bajo consumo

Código: `simulacion/funciones.R: prob_bajo_consumo(); script_principal.R: Inciso 4`

```
prob_bajo_consumo <- function(poblacion, c, j) {
  if (c <= 0)              stop("El umbral c debe ser positivo.")
  if (!(j %in% c(1, 2)))   stop("j debe ser 1 o 2.")
  columna <- paste0("x", j)
  mean(poblacion[[columna]] < c)   # proporción de hogares con x_j < c
}
```

Valor exacto para contrastar. $P(x_j^* < c) = P\Big(\frac{\alpha_j Y}{p_j} < c\Big) = P\Big(Y < \frac{c\,p_j}{\alpha_j}\Big) = F_{\chi^2_k}\Big(\frac{c\,p_j}{\alpha_j}\Big)$, que en R es `pchisq(c * p_j / alpha_j, df = k)`.

Definimos como umbral de bajo consumo $c = 1$ (la mitad del consumo medio del bien 1).

Bien j	Umbral c	$\hat{P}(x_j^* < c)$ simulada	$P(x_j^* < c)$ exacta
1	0.5	0.0088	0.0091
1	1	0.1097	0.1088
1	2	0.5655	0.5595
1	4	0.9710	0.9707
2	1	0.0020	0.0017
2	4	0.2432	0.2435

Alrededor del 11 % de los hogares consume menos de la mitad del consumo medio del bien 1. Las estimaciones por Monte Carlo están a menos de un punto porcentual del valor exacto en todos los casos (el error esperable con $n = 10{,}000$ es del orden de $\sqrt{p(1-p)/n} \approx 0.3$ p.p.).

3.5. Shock de precios

Código: `simulacion/script_principal.R: Inciso 5`

Simulamos $p_1' = 1.2\,p_1 = 2.4$ manteniendo p_2 y exactamente los mismos ingresos Y (los mismos 10,000 hogares). Así, cualquier diferencia entre escenarios se debe al precio y no al ruido de la simulación (*números aleatorios comunes*).

Efecto del shock hogar por hogar.

$$\frac{x_1^{*\prime}}{x_1^*} = \frac{\alpha_1 Y/(1.2p_1)}{\alpha_1 Y/p_1} = \frac{1}{1.2} \;\Rightarrow\; -16.7\,\%, \qquad \frac{x_2^{*\prime}}{x_2^*} = 1,$$

$$\frac{U^{*\prime}}{U^*} = \frac{Y(\alpha_1/1.2p_1)^{\alpha_1}(\alpha_2/p_2)^{\alpha_2}}{Y(\alpha_1/p_1)^{\alpha_1}(\alpha_2/p_2)^{\alpha_2}} = 1.2^{-\alpha_1} = 1.2^{-0.4} \approx 0.930 \;\Rightarrow\; -7.0\,\%.$$

El cambio es *proporcional e idéntico* para todos los hogares: la distribución de x_1^* se comprime hacia la izquierda por un factor $1/1.2$. La variación compensatoria (ingreso extra que devuelve al hogar a su utilidad inicial) es $VC_i = Y_i(1.2^{\alpha_1} - 1) \approx 0.0757\,Y_i$.

Variable	Escenario	Media	Desvío	Q_1	Mediana	Q_3
x_1^*	Pre	1.991	0.885	1.349	1.864	2.489
	Post	1.659	0.737	1.124	1.553	2.074
x_2^*	Pre = Post	5.972	2.655	4.046	5.591	7.467
U^*	Pre	3.848	1.711	2.607	3.603	4.812
	Post	3.578	1.591	2.424	3.350	4.473

Cambio porcentual medio por hogar: x_1^*: $-16.67\,\%$ (teórico $-16.67\,\%$); x_2^*: $0\,\%$; U^*: $-7.03\,\%$ (teórico $-7.03\,\%$).

3.6. Visualización comparada

Código: `simulacion/script_principal.R: Inciso 6; funciones.R: graficar_pre_post()`

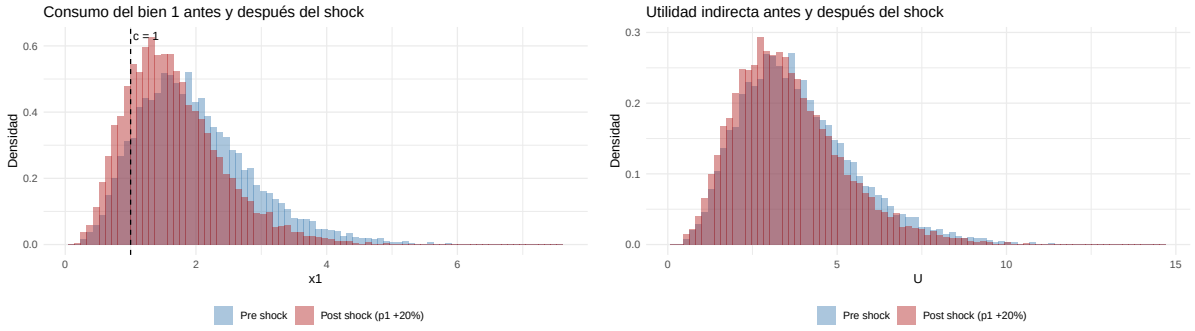


Figura 20: Histogramas superpuestos pre y post shock de x_1^* (izquierda, con el umbral $c = 1$) y de U^* (derecha).

Escenario	$\hat{P}(x_1^* < 1)$	$P(x_1^* < 1)$ exacta	$\bar{U}^*$
Pre shock	0.1097	0.1088	3.848
Post shock	0.1829	0.1847	3.578

Masa de bajo consumo. El shock desplaza toda la distribución de x_1^* hacia la izquierda: la proporción de hogares por debajo de $c = 1$ pasa de 11.0 % a 18.3 % (+7.3 p.p., un aumento de dos tercios). Los hogares que cruzan el umbral son los que antes consumían entre c y $1.2c$; equivalentemente, el umbral de ingreso para estar en bajo consumo sube de $Y < 5$ a $Y < 6$. Como la distribución del ingreso tiene mucha masa en esa zona, el efecto sobre la pobreza de consumo del bien 1 es grande aunque el shock sea *proporcional*.

Utilidad indirecta. La utilidad media cae de 3.85 a 3.58 (−7.0 %), justo $1.2^{-0.4} - 1$: cae menos que x_1^* porque el bien 1 pesa sólo un 40 % en las preferencias y el consumo de x_2^* no cambia. En dinero, compensar a los hogares requiere en promedio 0.75 unidades monetarias (7.6 % del ingreso medio). El consumo del bien 2 no se mueve porque, con Cobb–Douglas, el gasto en cada bien es una fracción fija del ingreso: los efectos ingreso y sustitución sobre x_2 se cancelan.

3.7. Heterogeneidad en preferencias

Código: `simulacion/script_principal.R: Inciso 7`

Ahora cada hogar sortea $\alpha_{1i} \sim \text{Beta}(a, b)$ y $\alpha_{2i} = 1 - \alpha_{1i}$. Para aislar el efecto de la *dispersión* de las preferencias, elegimos dos distribuciones con la misma media que el caso homogéneo, $E[\alpha_1] = a/(a+b) = 0.4$, y distinto desvío $\sqrt{ab/[(a+b)^2(a+b+1)]}$:

- Beta(4, 6): heterogeneidad moderada, desvío ≈ 0.15;
- Beta(0.8, 1.2): heterogeneidad alta, desvío ≈ 0.28 (hay hogares que casi no valoran el bien 1 y otros que gastan casi todo en él).

Se usan los mismos ingresos Y de antes y se repiten los incisos 3 a 6.

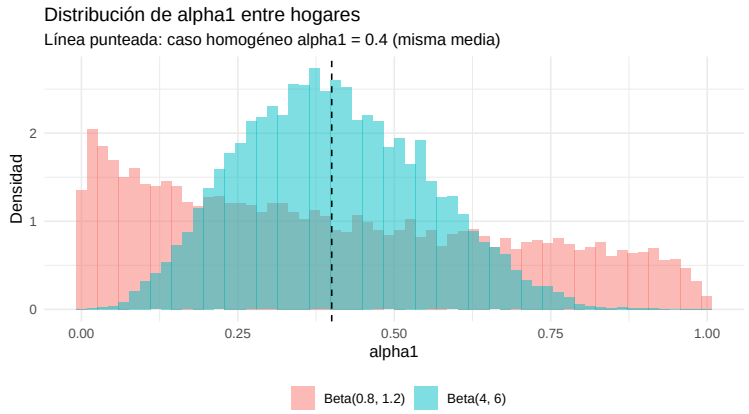


Figura 21: Distribución de α_1 entre hogares en los dos escenarios heterogéneos.

Inciso 3 con heterogeneidad

Variable	Escenario	Media	Desvío	Q_1	Mediana	Q_3
x_1^*	Homogéneo	1.991	0.885	1.349	1.864	2.489
	Beta(4, 6)	2.004	1.210	1.124	1.733	2.612
	Beta(0.8, 1.2)	1.999	1.783	0.620	1.521	2.909
x_2^*	Homogéneo	5.972	2.655	4.046	5.591	7.467
	Beta(4, 6)	5.945	3.072	3.724	5.378	7.581
	Beta(0.8, 1.2)	5.954	4.063	2.852	5.278	8.189
U^*	Homogéneo	3.848	1.711	2.607	3.603	4.812
	Beta(4, 6)	4.083	1.979	2.676	3.738	5.102
	Beta(0.8, 1.2)	4.914	2.934	2.932	4.224	6.107

Como α_{1i} es independiente de Y_i, $E[x_1^*] = E[\alpha_1]E[Y]/p_1 = 2$ en los tres casos: la heterogeneidad *no cambia las medias* de consumo, pero sí *aumenta su dispersión* (el desvío de x_1^* pasa de 0.89 a 1.78) y engorda la cola izquierda (el primer cuartil cae de 1.35 a 0.62). La utilidad media sube con la heterogeneidad, pero esto no significa que los hogares estén "mejor": la utilidad es ordinal y no se puede comparar entre hogares con preferencias distintas (mecánicamente, $V = Y\,f(\alpha_1)$ con f convexa, que vale más en los extremos). Por eso, para el bienestar usamos cambios porcentuales y la variación compensatoria, que se mide en dinero.

Incisos 4 a 6 con heterogeneidad: sensibilidad al shock

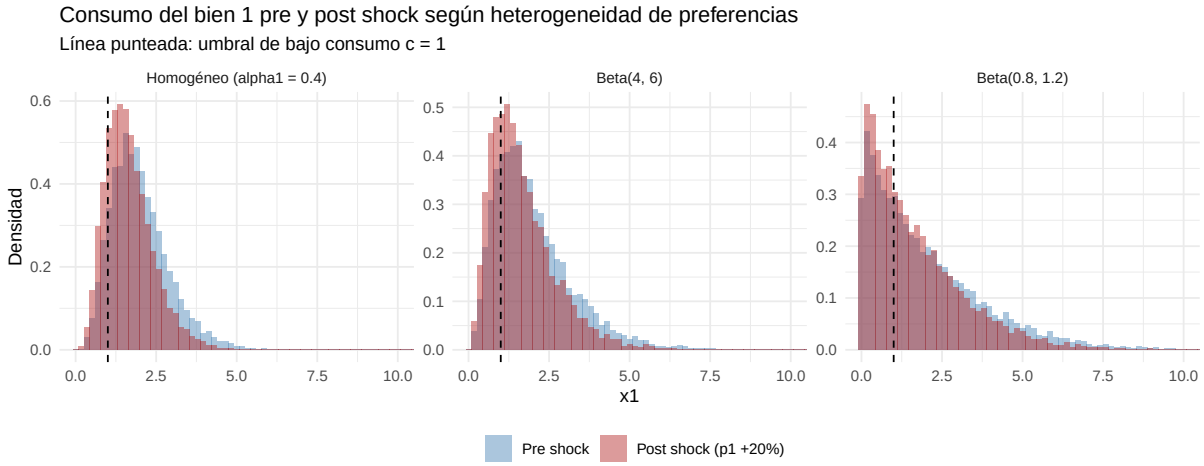


Figura 22: Histogramas superpuestos de x_1^* pre y post shock en cada escenario de preferencias.

	$\hat{P}(x_1^* < 1)$			ΔU^* por hogar		Var. compensatoria	
Escenario	Pre	Post	Δ (p.p.)	Media	[P10, P90]	Media	P90
Homogéneo	0.110	0.183	+7.3	−7.03 %	[−7.0 %, −7.0 %]	0.753	1.201
Beta(4, 6)	0.197	0.283	+8.6	−7.03 %	[−10.4 %, −3.8 %]	0.762	1.394
Beta(0.8, 1.2)	0.366	0.423	+5.7	−6.92 %	[−14.0 %, −0.9 %]	0.771	1.751

En los tres escenarios el consumo medio del bien 1 cae de ≈ 2.00 a ≈ 1.67 (−16.7 %).

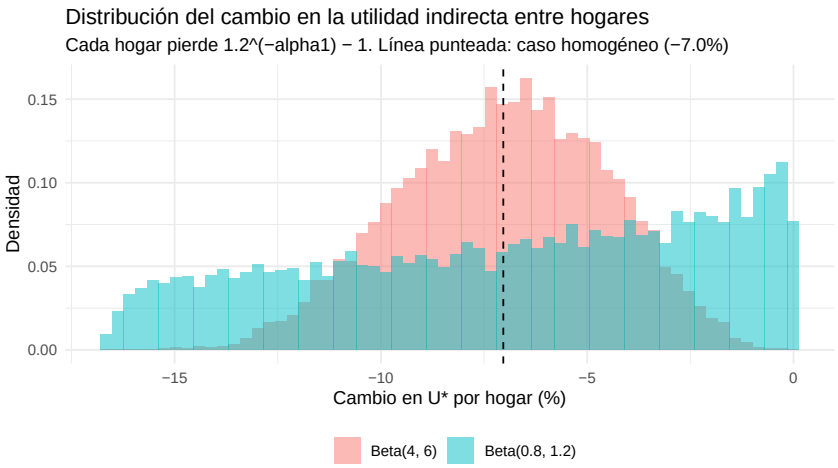


Figura 23: Distribución entre hogares del cambio porcentual en la utilidad indirecta.

1. La respuesta porcentual del consumo no depende de α_1. Cada hogar reduce x_1^* exactamente un 16.7 %, sea cual sea su preferencia, porque la elasticidad precio Cobb–Douglas es -1 para todos. En ese sentido, la heterogeneidad no cambia la sensibilidad *del consumo* al shock.
2. Sí cambia quién pierde y cuánto. La pérdida de utilidad de cada hogar es $1.2^{-\alpha_{1i}} - 1$: quienes más valoran el bien 1 pierden más. Con preferencias homogéneas todos pierden 7.0 %; con Beta(0.8, 1.2) el 10 % más afectado pierde más de 14 % y el 10 % menos afectado casi nada. La pérdida media casi no cambia: como $1.2^{-\alpha}$ es convexa en α, por Jensen $E[1.2^{-\alpha_1}] \geq 1.2^{-E[\alpha_1]}$, y la pérdida media es levemente menor (-6.92 % vs. -7.03 %). En dinero, la variación compensatoria media sube apenas (0.75 a 0.77) pero su cola se alarga mucho (P90 de 1.20 a 1.75).
3. La masa de bajo consumo responde de forma no monótona. Con más heterogeneidad hay muchos más hogares con bajo consumo *antes* del shock (11 %, 20 % y 37 %), porque aparecen hogares con α_1 cercano a cero. Pero el aumento provocado por el shock depende de cuánta masa hay justo por encima del umbral (entre c y $1.2c$): es mayor con heterogeneidad moderada (+8.6 p.p.) y menor con heterogeneidad alta (+5.7 p.p.), donde la distribución de x_1^* está más "aplanada" y muchos hogares ya estaban por debajo de c.

En síntesis, la dispersión en α_1 no altera la caída promedio del consumo ni casi la pérdida media de bienestar, pero redistribuye el costo del shock: lo concentra en los hogares que más valoran el bien cuyo precio sube. Para una política compensatoria, ignorar esa heterogeneidad llevaría a subcompensar a los más afectados.